```
library(dplyr)

rladies_global %>%
  filter(city == 'Buenos Aires')
```



# Intro a Web Scraping Con en Spotify Charts





### 1. Qué es Web Scraping?

El web scraping es una técnica que sirve para extraer información de páginas web de forma automatizada para su posterior análisis.



### 2. Web Scraping Ética

#### Tener en cuenta

- No vulnerar los derechos de propiedad intelectual
- Considerar que no estemos incurriendo en una conducta de competencia desleal
- No incumplir las normativas en protección de datos





### 3. Web Scraping Para qué se usa?

- Conocer las Tendencias del Momento
- Para la Compra/Venta de Servicios o Productos Sector inmobiliario
- Análisis de las reviews de Productos
- Páginas de comparación de precios
- Listado de eventos
- Documentación Pasada, Útil a Día de Hoy Abogacía
- En Recursos Humanos
- En tiempos de campañas electorales



# 4. Paquete rvest











Desarrollado por Hadley Wickham

#### Funciones:

- read\_html() Analiza gramaticalmente (parse) una página HTML.
- html\_nodes() Selecciona nodos de un documento HTML.
- html\_text() Extrae atributos, texto, nombres de tags de un HTML.



# 4. SpotifyCharts HTML









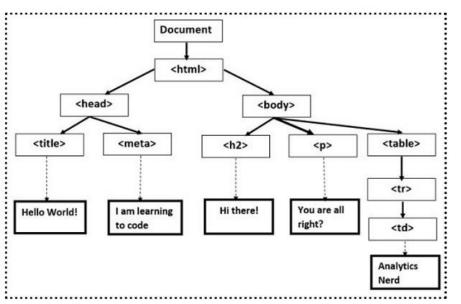
ightarrow DOWNLOAD TO CSV

TOP 2	200	VIRAL 50 Filter by ARGENTINA ▼	DAILY ▼ 05	/25/2019 ▼
		TRACK		STREAMS ?
	1	Otro Trago by Sech		494,549
	2	- Tal Vez by Paulo Londra		343,925
	3	- Pa Mí - Remix by Dalex		275,260
No.	4	- Soltera - Remix by Lunay		272,325
	5	- La Cobra by j mena		254,160
	6	Con Altura by ROSALÍA		224,963
	7	Solo Pienso En Ti (feat. De La Ghetto & Justin Quiles) by Paulo Londra		208,745
9	8	- Con Calma by Daddy Yankee		204,618



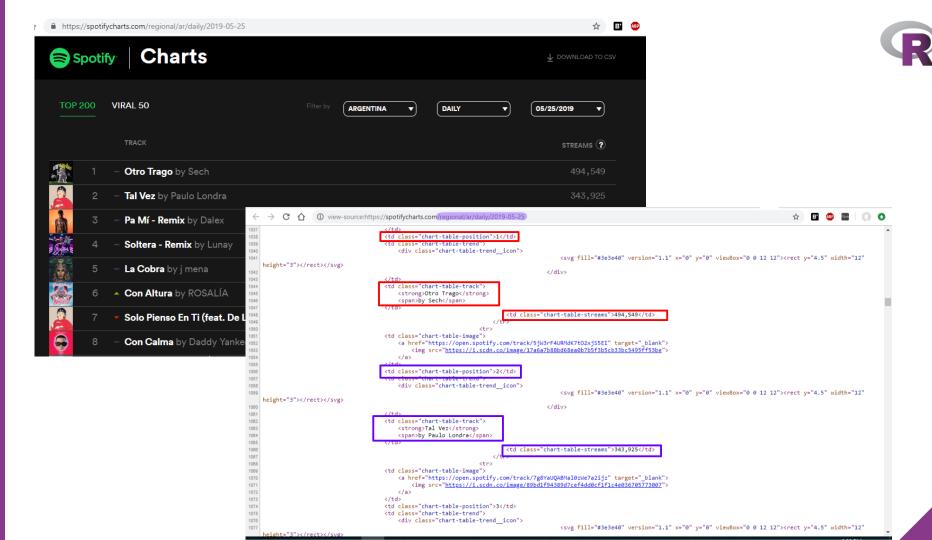
### Breve repaso de HTML

### Tags de HTML



#### Tabla en HTML

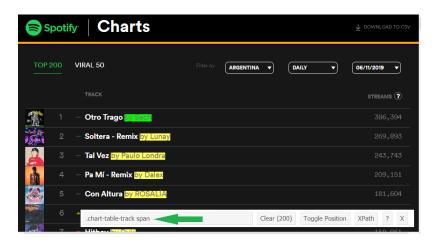
<TABLE HIEGHT=10 WIDTH=30 BORDER=0> <TH> Header1 </TH> <TH> Header2 </TH> <TD> </TD> <TR> <TD></TD> </TR> <TD></TD> <TD></TD> <TR> </TR> <TD></TD> <TD></TD> <TR> </TR> <TD></TD> <TD></TD> </TR> <TR> </TABLE>

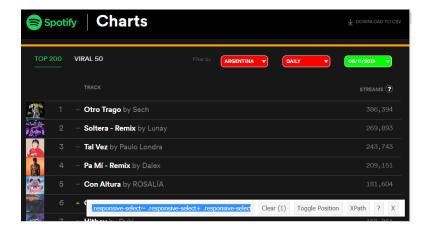




### Ayuda para identificar componentes HTML y CSS

Podemos ayudarnos del plugin para Chrome: **SelectorGadget** Para identificar los componentes de la pagina web.





https://cran.r-project.org/web/packages/rvest/vignettes/selectorgadget.html



## 5. Empecemos con el Script



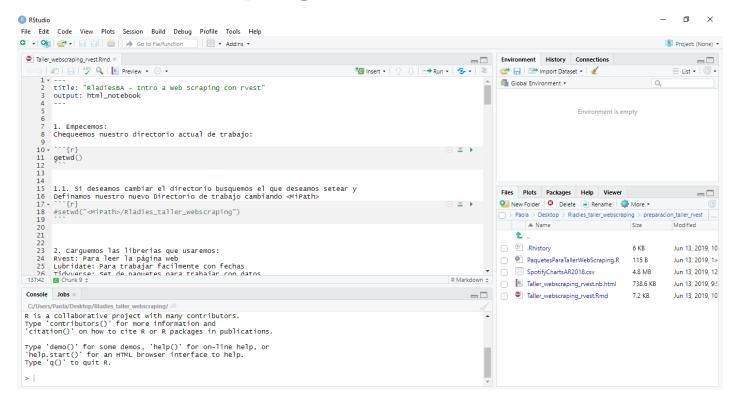






### 3. Script

### Taller\_webscraping\_rvest.Rmd





### Muchas Gracias!

Preguntas?





### Referencias

### Ética en Web Scraping

▶ Meme: <a href="https://stevenmortimer.com/scraping-responsibly-with-r/">https://stevenmortimer.com/scraping-responsibly-with-r/</a>

#### Paquete Rvest

https://CRAN.R-project.org/package=rvest

### Plugin para Chrome

https://cran.r-project.org/web/packages/rvest/vignettes/selectorgadget.html



### Referencias

- Jake Daniels, Scrape it yourself: Spotify Charts
   <a href="https://datacritics.com/2018/03/20/scrape-it-yourself-spotify-charts/">https://datacritics.com/2018/03/20/scrape-it-yourself-spotify-charts/</a>
- Scraping Spotify Data<a href="https://rpubs.com/argdata/web\_scraping">https://rpubs.com/argdata/web\_scraping</a>
- Iterating rvest scrape function gives: "Error in open.connection(x, "rb"): Timeout was reached"

https://stackoverflow.com/questions/39056103/iterating-rvest-scrape-function-gives-error-in-open-connectionx-rb-time